

Vorlesung

## **Statistische Methoden der Datenanalyse**

Prof. Dr. Dr. Wolfgang Rhode

---

Entfaltung II

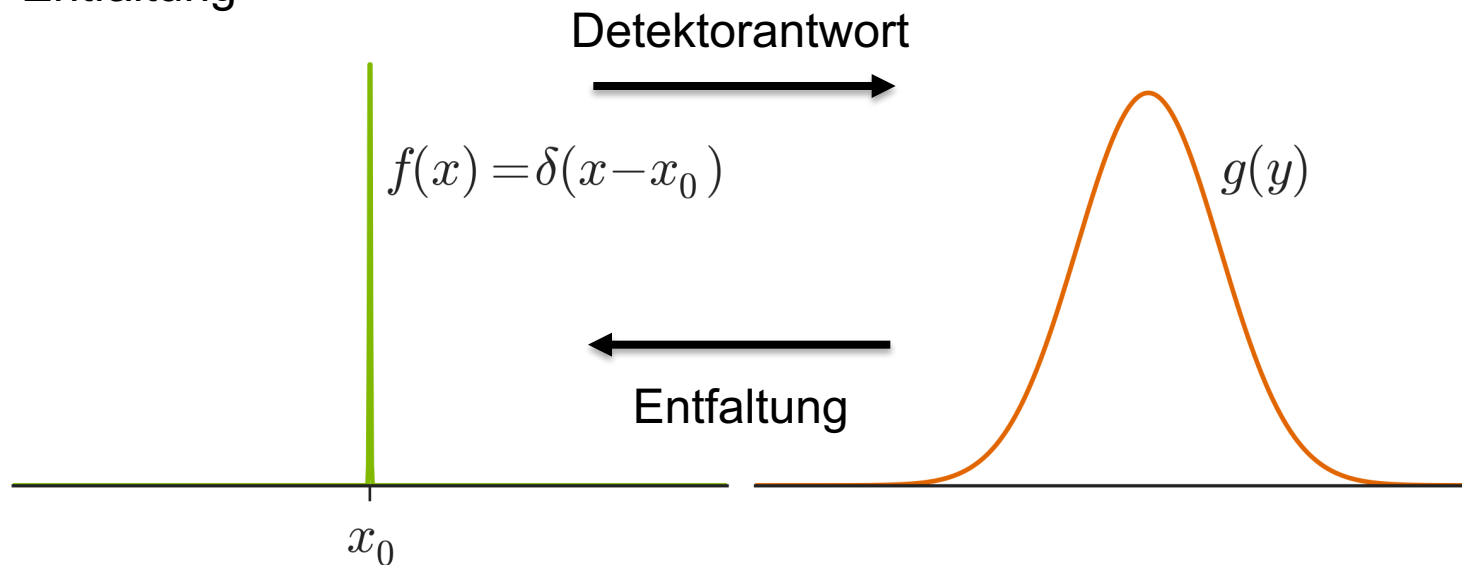
---

## Inhalt

- Wiederholung: Grundlagen der Entfaltung
- Beispiel: Pixeldetektor
- Binning
  - Eindimensionale Verfahren
  - Mehrdimensionale Verfahren
- Likelihood-Ansatz
  - Least-Squares-Ansatz
  - SVD
  - Iterative Bayesian Unfolding
  - Regularisierungsterme
  - Poisson-Ansatz
- Validierung

## Zusammenfassung: Entfaltung

- Direkte Messung einer Variable  $x$  unmöglich: Lediglich korrelierte Observable  $y$  ist verfügbar, Ergebnis eines stochastischen Prozesses
- Entfaltung



## Zusammenfassung: Entfaltung

- Migration der wahren physikalischen Größe in Observablen beschrieben durch *Fredholm*-Integralgleichung


$$g(y) = \int_{\Omega} A(x, y) f(x) dx + b(y)$$

- So nur schwer lösbar  $\rightarrow$  Diskretisierung  $\rightarrow$  Lineare Algebra

$$g_i = \sum_j A_{ij} f_j + b_i \iff \mathbf{g} = \mathbf{A} \cdot \mathbf{f} + \mathbf{b}$$

## Zusammenfassung: Entfaltung


- Problem: Oszillationen → Schlecht konditioniertes Problem



- Grund: Kleine, statistisch insignifikante Eigenwerte der Migrationsmatrix

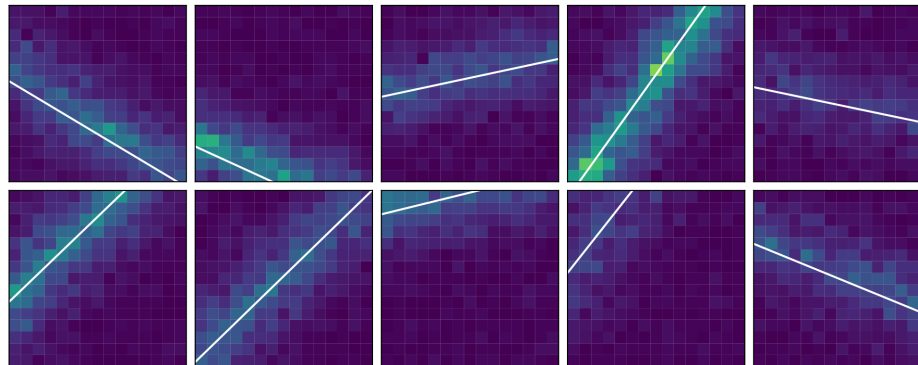
## Zusammenfassung: Entfaltung

- Lösung: Regularisierung durch Abschneiden von Beiträgen kleiner Eigenwerte



## Beispiel: Ein einfacher Pixeldetektor


- Einfaches Beispiel: 2d-Pixeldetektor mit 8x8 Pixeln
  - Teilchen fallen aus beliebigen Richtungen mit diversen Energien ein
  - Energieverluste der Teilchen etwa proportional zu Energie des Teilchens
  - In Folge der Energieverluste werden Photonen im Pixeldetektor deponiert
- Deponierte Ladung im Detektor ist Maß für Energie des Teilchens



10 simulierte Beispielergebnisse

## Beispiel: Ein einfacher Pixeldetektor

- Problem: Zuordnung zwischen deponierter Ladung und ursprünglichen Energie des Teilchens ist nicht 1:1
- Fragestellung: Welcher Verteilung folgt die Energie des Teilchens an der Quelle?






## Beispiel: Ein einfacher Pixeldetektor

- Observable: Summe der deponierten Ladung im Detektor
    - Messbare Größe im echten Experiment
  - Entfaltungsvariable: Ursprüngliche Energie des detektierten Teilchens
    - Nur verfügbar in Simulationen
- Nutze Simulationen um Migrationsmatrix zu berechnen

## Beispiel: Ein einfacher Pixeldetektor



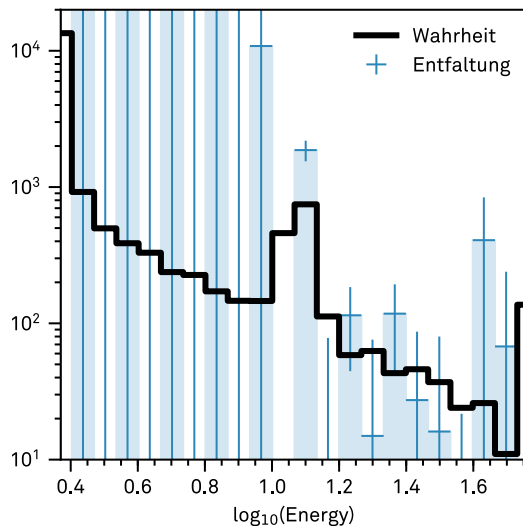
## Binning: Binning des Observablenraumes

### Generelle Bemerkungen:

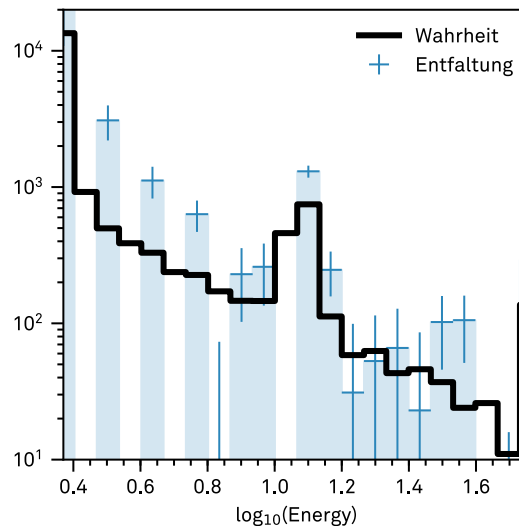
- Je feiner der Observablenraum gebinnt ist, desto besser bestimmt ist mein Entfaltungsproblem
  - Je gröber der Observablenraum gebinnt wird, desto kleiner sind die relativen statistischen Unsicherheiten der Bininhalte
- Wahl des Binnings ist ein Kompromiss!

## Binning: Binning des Observablenraumes

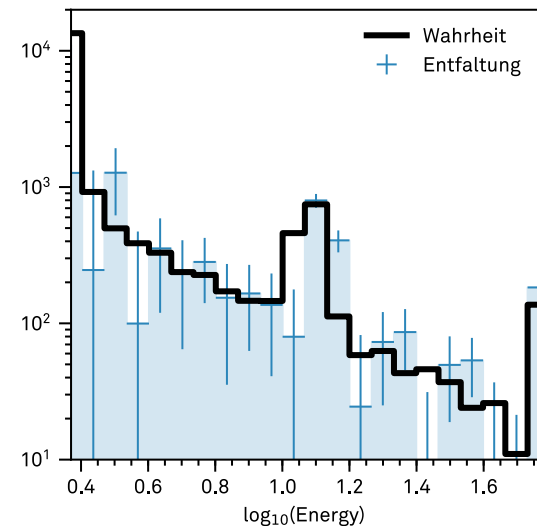
20 Bins



100 Bins




1000 Bins





## Binning: Mehrdimensionales Binning

- Oft ist es nützlich nicht nur die eine Observable zu betrachten, sondern mehrere Observablen
- Events haben alle die gleiche Energie, aber deutlich unterschiedliche Gesamtladungen
- Zusammenhang zwischen Gesamtladung und Energie ist abhängig von der Position des Tracks!

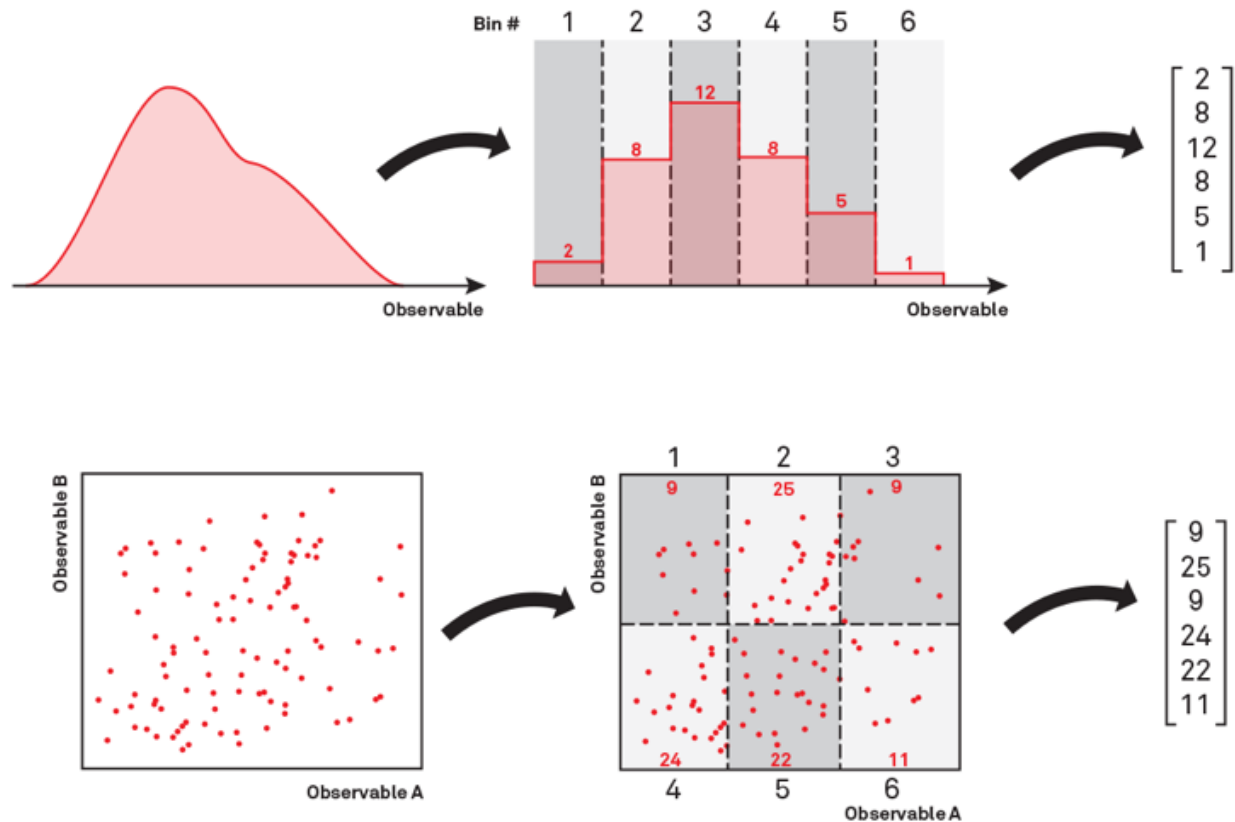


## Binning: Mehrdimensionales Binning

- Oft ist es nützlich nicht nur die eine Observable zu betrachten, sondern mehrere Observablen
- Events haben alle die gleiche Energie, aber deutlich unterschiedliche Gesamtladungen
- Zusammenhang zwischen Gesamtladung und Energie ist abhängig von der Position des Tracks!




## Binning: Mehrdimensionales Binning



## Binning: Mehrdimensionales Binning

- Problem: *Curse of Dimensionality*
  - Binnt man  $d$  Observablen in  $n$  äquidistante Bins, so erhält man insgesamt  $n^d$  Bins
  - Die meisten dieser Bins sind nur sehr dünn besiedelt, dadurch steigt die statistische Unsicherheit in der Migrationsmatrix
- Keine skalierbare Lösung






## Binning: Mehrdimensionales Binning

### Alternative: Binning mit Entscheidungsbäumen

- Nutze einen Entscheidungsbaum um den Observablenraum zu unterteilen
- Die Blätter des Entscheidungsbaums können dann als Bins verwendet werden



## Entfaltung als Maximum-Likelihood-Problem

- Schlechte Kondition des Problems macht eine Regularisierung notwendig
  - Ein flexibler Ansatz ist notwendig mit dem sich A-Priori-Wissen in statistisch sinnvoller Weise nutzen lässt
- Maximierung einer Likelihood-Funktion
- **Idee:** Gegeben der statistische Prozess dem die Messung unterliegt, was ist die wahrscheinlichste *wahre Physik*, die diese Messung hervorgerufen hat?

## Likelihood-Methoden: Likelihood-Funktion

- Die generelle Form einer Likelihood-Funktion im Falle der Entfaltung ist

$$\mathcal{L} = \mathcal{L}_{\text{stat}} + \mathcal{L}_{\text{reg}}$$

- Der erste Term soll hierbei generell die Übereinstimmung der Messung mit der vorhergesagten Detektor-Antwort gegeben eines Entfaltungsergebnisses bemessen.
- Der zweite Term beinhaltet Regularisierungsterme, die verschiedene Formen haben können. Generell stellen diese Terme Annahmen über die Lösung dar, z.B. Glattheit der Lösung oder unplausible Wertebereiche.

## Likelihood-Methoden: Erster Term

- Im allgemeinsten Sinne beschreibt der Term den statistischen Prozess mit dem der Messprozess modelliert wird.
- Dies kann prinzipiell jede Statistik sein, in der Praxis jedoch sind einige Modelle von besonders großer Bedeutung.
- Die Summe der quadratischen Abweichungen:

$$\mathcal{L}_{\text{MSE}} = \sum_i (\mathbf{g} - \mathbf{A} \cdot \mathbf{f})_i^2 = (\mathbf{g} - \mathbf{A} \cdot \mathbf{f})^\top (\mathbf{g} - \mathbf{A} \cdot \mathbf{f})$$

- Hierbei wird der Messprozess als Gaußscher Prozess angenommen, wobei die Kovarianz eine Einheitsmatrix ist und der Erwartungswert die vorhergesagte Detektorantwort.

## Likelihood-Methoden: Erster Term

- Der häufigste Anwendungsfall der Entfaltung sind Zählexperimente. Hierbei stellen die Elemente des Vektors **g** Zählraten dar.
- Die naheliegenste statistische Beschreibung eines solchen Experiments ist die Poisson-Statistik:

$$\mathcal{L}_{\text{Poisson}} = \sum_i g_i \log((\mathbf{A} \cdot \mathbf{f})_i) - (\mathbf{A} \cdot \mathbf{f})_i$$

## Least Squares: Analytische Lösung

- Die Least-Squares-Likelihood hat dabei eine analytische Lösung. Für quadratische Matrizen ist diese trivial:

$$\nabla \log \mathcal{L} = 2(A \cdot \mathbf{f} - \mathbf{g}) \stackrel{!}{=} 0 \implies \mathbf{f} = A^{-1} \mathbf{g}$$

- Für nicht-quadratische Matrizen muss man einen kleinen Umweg gehen:

$$\begin{aligned} \nabla \log \mathcal{L} = 2(A \cdot \mathbf{f} - \mathbf{g}) \stackrel{!}{=} 0 &\implies A^{\top} A \cdot \mathbf{f} = A^{\top} \mathbf{g} \\ &\implies \mathbf{f} = (A^{\top} A)^{-1} A^{\top} \mathbf{g} = A^{+} \mathbf{g} \end{aligned}$$

## Least Squares: Singular Value Decomposition (SVD)

- $A^+$  wird auch als Pseudoinverse bezeichnet und lässt sich als Verallgemeinerung der Inversen verstehen
- Ähnlich kann man auch die Eigenwertzerlegung verallgemeinern, die sog. Singulärwertzerlegung (Singular Value Decomposition, SVD)

$$A \cdot \mathbf{f} = U \Sigma V^T \cdot \mathbf{f} = \mathbf{g} \iff V \Sigma^+ U^T \cdot \mathbf{g} = \mathbf{f}$$

## Least Squares: Singular Value Decomposition (Regularisierung)

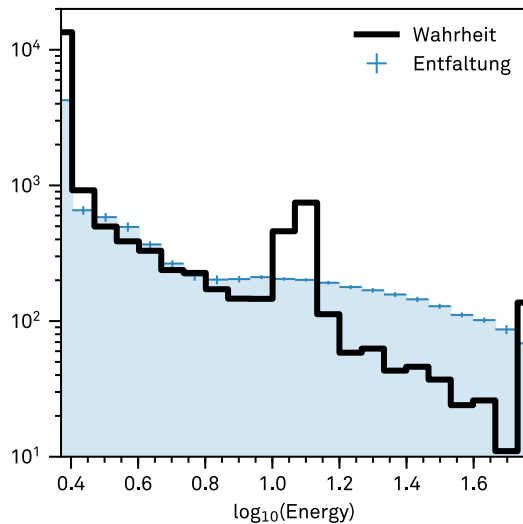
- In dieser Zerlegung lässt sich nun eine Regularisierung einführen, indem kleine Singulärwerte unterdrückt werden:

$$A^+ \cdot \mathbf{g} = V\Sigma^+U^\top \cdot \mathbf{g} = \mathbf{f} \longrightarrow A_{\text{reg}}^+ \cdot \mathbf{g} = V\Sigma^+ \text{diag}(\tau)U^\top \cdot \mathbf{g} = \mathbf{f}$$

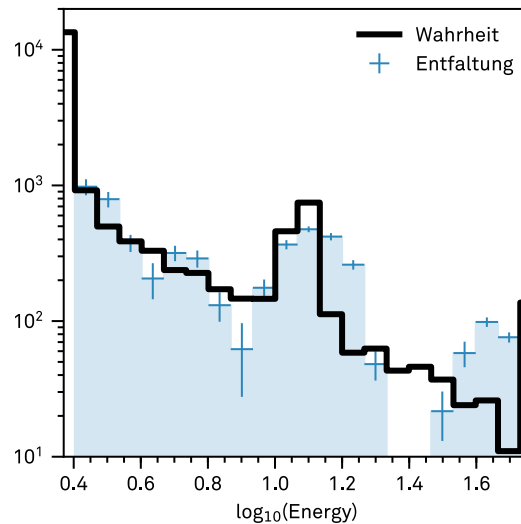


## SVD-Entfaltung


Größte 5  
Singulärwerte



Größte 10  
Singulärwerte



Größte 15  
Singulärwerte



Regularisierungsstärke

Entfaltung

## Iterative Bayesian Unfolding

- In diesem Ansatz wird der Satz von Bayes benutzt um die Inverse der Migrationsmatrix iterativ anzunähern (siehe Vorlesung zum Thema *Schätzen*)
- Hierzu schreiben wir die Entfaltungsgleichung wie folgt um:

$$\mathbf{g} = \mathbf{A} \cdot \mathbf{f} \iff g(y_j) = \sum_i A(y_j|x_i) f(x_i)$$

- Die Migrationsmatrix  $A_{ij}$  wird mit Hilfe von Simulationsdaten berechnet, wobei durch die spaltenweise Normierung diese explizit modellunabhängig ist:

$$A(y_j|x_i) = \frac{A(x_i, y_j)}{\sum_j A(x_i, y_j)} = \frac{A(x_i, y_j)}{f(x_i)}$$

## Iterative Bayesian Unfolding

- In dieser Formulierung kann man die Lösung der Entfaltungsgleichung wie folgt schreiben:

$$f(x_i) = \sum_j B(x_i|y_j)g(y_j) \quad (1)$$

- Hierbei tritt jedoch das Problem auf, dass  $B_{ji}$  nicht mehr modellunabhängig ist, d.h. die Lösung fällt unterschiedlich aus, je nachdem mit welchen Annahmen über den Fluss simuliert wurde.

## Iterative Bayesian Unfolding

- Nutze nun den Satz von Bayes mit dem  $f$  aus der vorherigen Berechnung als Prior, um erneut die Matrix  $B$  zu berechnen:

$$B(x_i|y_j) = \frac{A(y_j|x_i)\hat{f}(x_i)}{\sum_i A(y_j|x_i)\hat{f}(x_i)} \quad (2)$$

- Dieses Verfahren kann nun iterativ fortgeführt werden, indem die Matrix aus (2) wieder in (1) eingesetzt wird um die nächste Iteration von  $f$  zu berechnen.

## Iterative Bayesian Unfolding

- Dieses Vorgehen bezeichnet man als *Iterative Bayesian Unfolding*:


$$B^{(k+1)}(x_i|y_j) = \frac{A(y_j|x_i)f^{(k)}(x_i)}{g(y_j)}$$
$$f^{(k+1)}(x_i) = \sum_i B^{(k+1)}(x_i|y_j)g(y_j)$$

- Die Abbruchsbedingung ist entweder Konvergenz oder eine festgelegte Schrittzahl

## Iterative Bayesian Unfolding: Konvergenz?


- Der Algorithmus lässt sich auch auffassen als Minimierung einer einfachen Least-Squares-Likelihood
- Das hat zur Folge, dass bei Konvergenz des Algorithmus die gleichen Probleme wie bei der unregularisierten SVD-Entfaltung auftreten (Oszillationen etc)
- Jedoch konvergieren die großen Eigenwerte schneller, als die Kleinen  
→ Früher Abbruch führt zu Vermeidung von Artefakten

## Iterative Bayesian Unfolding




# Iterative Bayesian Unfolding


$k = 1$



$k = 5$



$k = 200$



Regularisierungsstärke



## Likelihood-Methoden: Zweiter Term

- Die Einführung zusätzlicher Annahmen über die Lösung des Entfaltungsproblems kann helfen, das Problem besser zu konditionieren.
- Generell gilt die Regel: So wenige Annahmen wie möglich, so viele wie nötig.
- Eine Möglichkeit ist es, den Wertebereich der Lösung einzuschänken, z.B. weil bekannt ist, dass physikalische Flüsse nicht negativ sind:

$$\mathcal{L}_+(\mathbf{f}) = \begin{cases} \infty & \text{wenn mindestens ein } f_i < 0 \\ 0 & \text{sonst} \end{cases}$$

## Likelihood-Methoden: Tikhonov-Regularisierung

- Oft ist es hilfreich eine glatte Lösung zu fordern. Hierzu definiert man “Glattheit” als eine durchweg kleine zweite Ableitung.
- Numerisch kann die zweite Ableitung eines Vektors durch Anwendung einer Matrix (s. regularisierte kleinste Quadrate) erreicht werden:

$$C = \begin{bmatrix} 1 & -1 & 0 & \dots & & \\ -1 & 2 & -1 & \dots & & \\ 0 & -1 & \ddots & & \vdots & \vdots \\ \vdots & \vdots & & \ddots & -1 & 0 \\ & & \dots & -1 & 2 & -1 \\ & & \dots & 0 & -1 & 1 \end{bmatrix}$$

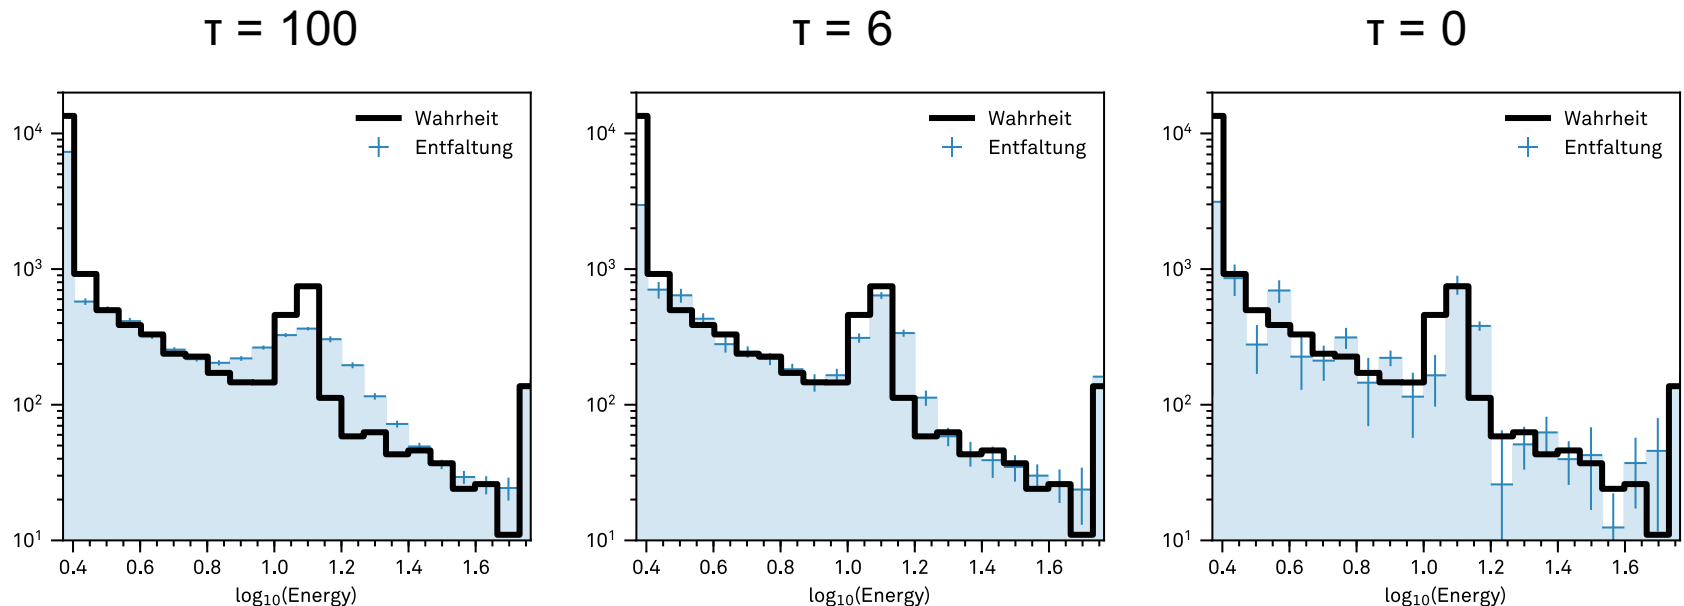
## Likelihood-Methoden: Tikhonov-Regularisierung

- Anschließend wird die Summe der Quadrate der zweiten Ableitungen als Maß für die Glattheit der Lösung berechnet:

$$\mathcal{L}_{\text{tikh}}(\mathbf{f}) = \frac{\tau}{2} \sum_i \|\mathbf{C} \cdot \mathbf{f}\|_i^2 = \frac{\tau}{2} \mathbf{f}^\top \mathbf{C}^\top \mathbf{C} \mathbf{f}$$

- Der Vorfaktor  $\tau$  wird als Regularisierungsstärke bezeichnet und ist ein Maß dafür, wie stark Nicht-Glattheit bestraft wird.
- Der Term lässt sich auch als Gaußscher Prior auf die zweiten Ableitungen verstehen. (→ Bayesianische Statistik)

## Likelihood-Methoden: Numerische Minimierung



Regularisierungsstärke

## Validierung: Varianz und Bias

- Regularisierungen sind Annahmen, die man über das Spektrum macht, die dazu führen, dass bestimmte Bereiche der Lösung ausgeschlossen oder unterdrückt werden
- Da das Spektrum im Regelfall unbekannt ist, passen die Annahmen, die man einführt nicht zwingend zum vorliegenden Datensatz
- Falsche Annahmen über das Ergebnis sorgen für einen Bias
- Einschränkung der Lösung führt zu einer Unterschätzung der Fehler

## Validierung: Varianz und Bias

- Um abzuschätzen wie ausgeprägt diese systematischen Effekte sind, kann man auf Grundlage von Simulationen das Entfaltungsergebnis mit der Wahrheit vergleichen. Hier zu kann folgende Teststatistik berechnet werden:

$$\Lambda_i = \frac{\hat{f}_i - f_i}{\sigma_{\hat{f}}}$$

- Diese Abweichung des entfalteten Bininhalts von der Wahrheit, normiert auf den geschätzten Fehler, sollte im Fall eines erwartungstreuen Schätzers standardnormalverteilt sein.
- Nur nicht-regularisierte Entfaltung ist erwartungstreu

## Validierung: Varianz und Bias

